

UNIVERSITÉ POLYTECHNIQUE DE GITEGA

BAC 4 – GÉNIE LOGICIEL

TRAVAUX PRATIQUES

IA Appliqué à l'Agriculture

Prédire les Bonnes et Mauvaises Récoltes au Burundi

Contexte

L'agriculture représente plus de **40 % du PIB du Burundi** et constitue la principale source de revenus pour plus de 90 % de la population rurale. Pourtant, les rendements agricoles restent très faibles et très variables d'une saison à l'autre, selon les provinces, les cultures et les conditions climatiques.

Dans ce TP, vous allez utiliser des **données agricoles réelles simulées** sur 15 provinces du Burundi (2015–2023) pour construire des modèles de Machine Learning capables de **prédire si une récolte sera bonne ou mauvaise** en fonction de facteurs mesurables : pluviométrie, température, altitude, utilisation d'engrais, etc.

DESCRIPTION DU DATASET

Le fichier agriculture_burundi.csv contient **1 620 observations** couvrant 9 années (2015–2023), 2 saisons agricoles (A et B), 15 provinces et 6 cultures principales du Burundi. Chaque ligne représente les données d'une culture dans une province pour une saison donnée.

Variable	Type	Unité	Description
annee	Entier	—	Année agricole (2015 à 2023)
saison	Catégoriel	A / B	Saison A (mars–juin), Saison B (sept–déc)
province	Catégoriel	—	15 provinces du Burundi
culture	Catégoriel	—	Maïs, Haricot, Manioc, Patate douce, Sorgho, Bananier
altitude_m	Numérique	mètres	Altitude moyenne de la zone cultivée

pluviometrie_mm	Numérique	mm	Pluviométrie totale de la saison
temperature_moy_C	Numérique	°C	Température moyenne de la saison
superficie_ha	Numérique	hectares	Superficie totale cultivée
utilisation_engrais	Binaire	0 / 1	1 = engrais utilisé, 0 = aucun engrais
acces_irrigation	Binaire	0 / 1	1 = accès à l'irrigation, 0 = culture pluviale
nb_menages	Entier	—	Nombre de ménages agricoles concernés
rendement_t_ha	Numérique	t/ha	Rendement moyen par hectare
production_totale_t	Numérique	tonnes	Production totale = rendement × superficie
bonne_recolte	Binaire	0 / 1	1 = bonne récolte, 0 = mauvaise récolte (VARIABLE CIBLE)

Variable cible

La variable cible `bonne_recolte` est définie à partir du rendement : une récolte est considérée « bonne » si le rendement dépasse 85 % du rendement moyen attendu pour la culture concernée. Elle contient quelques valeurs manquantes (~2,5 %).

Attention

Le dataset contient intentionnellement des valeurs manquantes (~3–4 % des lignes). Vous devrez les détecter et les traiter correctement avant l'entraînement.

EXERCICE 1

Chargement, Exploration et Qualité des Données

20 pts points

Objectif : Charger le dataset, comprendre sa structure, identifier les problèmes de qualité et formuler des premières hypothèses sur les facteurs influençant les récoltes.

1.1 Chargement des données

Commencez par charger le fichier `agriculture_burundi.csv` et effectuez une première inspection.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# Chargez le dataset ici
df = pd.read_csv('agriculture_burundi.csv')
```

Q1. Combien y a-t-il de lignes et de colonnes dans ce dataset ?

- ↳ Quelle est la période couverte (années) ?
- ↳ Combien de provinces distinctes sont représentées ?
- ↳ Quelles sont les 6 cultures présentes ?

Q2. Affichez les types de données de chaque colonne (dtypes). Y a-t-il des types incohérents par rapport à la description du dataset ? Si oui, lesquels et pourquoi ?

1.2 Qualité des données — Valeurs manquantes

Q3. Calculez le nombre et le pourcentage de valeurs manquantes pour chaque colonne.

- ↳ Quelles colonnes sont concernées ?
- ↳ Le taux de manquants est-il homogène entre les provinces et les cultures ?

Aide

Conseil : utilisez `df.isnull().sum()` et `df.isnull().mean()*100` pour un premier aperçu.
Pour croiser les manquants avec les provinces, pensez à `groupby()`.

Q4. Choisissez et justifiez une stratégie pour traiter les valeurs manquantes de chaque colonne concernée.

- ↳ Suppression des lignes ? Imputation par la moyenne/médiane ? Imputation par groupe (culture, province) ?
- ↳ Appliquez votre stratégie et vérifiez qu'il n'y a plus de valeurs manquantes.

1.3 Exploration statistique

Q5. Calculez les statistiques descriptives (moyenne, médiane, écart-type, min, max) pour les variables numériques.

- ↳ Quelle culture présente le rendement moyen le plus élevé ? Le plus faible ?
- ↳ Quelle province a la pluviométrie moyenne la plus forte ?

Q6. Analysez la distribution de la variable cible `bonne_recolte`.

- ↳ Quelle est la proportion de bonnes récoltes (classe 1) et de mauvaises récoltes (classe 0) ?
- ↳ Ce dataset est-il équilibré ? Quelle conséquence cela peut-il avoir sur l'entraînement ?

Q7. Produisez au minimum 3 visualisations pertinentes et commentez chacune.

- ↳ Distribution du rendement par culture (boxplot)
- ↳ Évolution de la production totale par année (lineplot)
- ↳ Proportion de bonnes récoltes selon l'utilisation d'engrais (barplot)
- ↳ Matrice de corrélation entre les variables numériques (heatmap)

EXERCICE 2**Prétraitement et Préparation des Données****15 pts points**

Objectif : Transformer les données brutes en un format utilisable par les algorithmes de Machine Learning : encodage des variables catégorielles, normalisation des variables numériques et construction des jeux train/test.

2.1 Encodage des variables catégorielles

Q8. Identifiez toutes les variables catégorielles du dataset.

- ↳ Pourquoi ne peut-on pas les utiliser directement comme variables d'entrée ?
- ↳ Quelle est la différence entre LabelEncoder et `pd.get_dummies()` (One-Hot Encoding) ?
- ↳ Dans ce contexte, laquelle est la plus adaptée pour la variable province ? Pour culture ? Pour saison ? Justifiez.

Q9. Appliquez l'encodage choisi à chaque variable catégorielle.

- ↳ Combien de colonnes le dataset compte-t-il après encodage ?
- ↳ Avez-vous pensé au problème de la « dummy variable trap » avec `get_dummies` ?

Rappel important

Rappel — Dummy variable trap : si vous utilisez `get_dummies` sur une variable à k catégories, vous obtenez k colonnes. Il faut en supprimer une (`drop_first=True`) pour éviter la multicolinéarité. Ce problème affecte surtout la régression logistique.

2.2 Sélection des variables et normalisation

Q10. Définissez votre matrice de features X et votre vecteur cible y .

- ↳ Quelles colonnes excluez-vous et pourquoi ? (Ex : `rendement_t_ha` et `production_totale_t` — pourquoi ?)
- ↳ Y a-t-il un risque de data leakage si on garde `rendement_t_ha` dans X ?

Q11. Appliquez une normalisation sur les variables numériques de X .

- ↳ Pourquoi la normalisation est-elle nécessaire pour la régression logistique mais moins critique pour les arbres de décision ?

- ↳ Après normalisation, quelle est la moyenne et l'écart-type des colonnes numériques ?

2.3 Division Train / Test

Q12. Divisez les données en 80 % train et 20 % test.

- ↳ Utilisez stratify=y. Expliquez pourquoi cette option est importante ici.
- ↳ Vérifiez que la proportion de bonnes/mauvaises récoltes est similaire dans les deux ensembles.
- ↳ Pourquoi faut-il impérativement fixer random_state ? Que se passerait-il sans ?

EXERCICE 3

Arbre de Décision — Entraînement et Visualisation

20 pts points

Objectif : Construire un arbre de décision pour prédire les bonnes récoltes, analyser les règles apprises et étudier l'impact des hyperparamètres.

3.1 Entraînement du modèle de base

Q13. Entraînez un arbre de décision avec max_depth=4 et criterion='gini'.

- ↳ Quelle est l'accuracy obtenue sur le jeu de test ?
- ↳ Affichez le rapport de classification complet (precision, recall, F1 pour chaque classe).

Q14. Calculez et affichez la matrice de confusion.

- ↳ Combien de fausses alertes (faux positifs) le modèle produit-il ?
- ↳ Combien de mauvaises récoltes le modèle a-t-il manqué (faux négatifs) ?
- ↳ Dans un contexte agricole réel, quel type d'erreur est le plus coûteux pour un agriculteur ?

3.2 Visualisation de l'arbre

Q15. Visualisez l'arbre de décision construit (plot_tree).

- ↳ Quelle est la variable utilisée pour le premier split (racine de l'arbre) ?
- ↳ Interpréter ce premier noeud : quelle est la règle apprise et que signifie-t-elle agronomiquement ?
- ↳ L'arbre utilise-t-il la pluviométrie dans ses premières décisions ? Cela vous surprend-il ?

Q16. Affichez l'importance des variables (feature_importances_).

- ↳ Les 3 variables les plus importantes sont-elles cohérentes avec votre intuition agronomique ?
- ↳ La variable utilisation_engrais est-elle importante ? Quel message cela envoie-t-il aux décideurs ?

3.3 Impact des hyperparamètres — Analyse de l'overfitting

Q17. Faites varier `max_depth` de 1 à 20 et tracez un graphique montrant l'accuracy train ET test en fonction de la profondeur.

- ↳ À partir de quelle profondeur observe-t-on un surapprentissage (overfitting) ?
- ↳ Quelle profondeur offre le meilleur équilibre biais/variance ?
- ↳ Expliquez en vos propres mots le phénomène d'overfitting dans le contexte agricole.

Aide

Piste de code : utilisez une boucle `for depth in range(1, 21)` pour entraîner un arbre à chaque profondeur, calculez `train_score` et `test_score`, stockez dans des listes, puis tracez avec `plt.plot()`.

EXERCICE 4 Forêt Aléatoire — Robustesse et Comparaison

20 pts points

Objectif : Entraîner une forêt aléatoire, comprendre pourquoi elle performe mieux qu'un seul arbre et analyser sa robustesse par validation croisée.

4.1 Entraînement de la forêt aléatoire

Q18. Entraînez une forêt aléatoire avec `n_estimators=100` arbres.

- ↳ Comparez immédiatement son accuracy avec celle de l'arbre de décision (exercice 3).
- ↳ La forêt est-elle meilleure ? De combien de points d'accuracy ?

Q19. Expliquez en vos propres mots pourquoi une forêt de 100 arbres est généralement plus performante qu'un seul arbre de décision.

- ↳ Qu'est-ce que le bagging ?
- ↳ Qu'apporte la sélection aléatoire des features à chaque noeud (paramètre `max_features`) ?
- ↳ La forêt peut-elle surapprendre ? Dans quelles conditions ?

4.2 Validation croisée (Cross-Validation)

Q20. Évaluez la forêt aléatoire par validation croisée à 5 folds (`cross_val_score`).

- ↳ Quelle est la moyenne et l'écart-type de l'accuracy sur les 5 folds ?
- ↳ Comparez avec l'accuracy simple sur le jeu de test. Y a-t-il une grande différence ?

- ↳ Pourquoi la validation croisée est-elle une mesure plus fiable de la performance réelle ?

Rappel

La validation croisée divise les données en k groupes (folds). Le modèle est entraîné k fois, chaque fois en utilisant $k-1$ folds pour l'entraînement et 1 fold pour le test. La performance finale est la moyenne sur les k évaluations.

4.3 Importance des variables et analyse

Q21. Affichez l'importance des variables de la forêt aléatoire sous forme de graphique à barres horizontales (triées du plus important au moins important).

- ↳ Comparez le top-5 des variables importantes avec celui de l'arbre de décision.
- ↳ Y a-t-il des différences ? Lesquelles ? Comment les expliquer ?

Q22. Faites varier `n_estimators` (nombre d'arbres) de 10 à 500 et observez l'impact sur l'accuracy test.

- ↳ À partir de combien d'arbres la performance se stabilise-t-elle ?
- ↳ Quel est le compromis à faire entre nombre d'arbres et temps de calcul ?

EXERCICE 5

Régression Logistique — Interprétabilité et Courbe ROC

20 pts points

Objectif : Entraîner une régression logistique, interpréter ses coefficients en termes agronomiques et comparer les trois modèles sur la courbe ROC.

5.1 Entraînement et interprétation des coefficients

Q23. Entraînez une régression logistique avec `max_iter=1000`.

- ↳ Quelles sont les variables avec les coefficients les plus positifs ? Que signifient-elles ?
- ↳ Quelles variables ont des coefficients négatifs ? Cela est-il cohérent avec la réalité ?

Aide à l'interprétation

Dans une régression logistique, un coefficient positif signifie que quand la variable augmente, la probabilité d'avoir une bonne récolte augmente aussi. Un coefficient négatif signifie l'inverse. Attention : les coefficients ne sont interprétables que si les variables sont normalisées (ce que vous avez fait à l'étape 2).

Q24. La régression logistique est-elle plus ou moins performante que les deux modèles précédents en termes d'accuracy ? Proposez une explication.

- ↳ La régression logistique suppose une relation linéaire entre les features et la log-probabilité. Cette hypothèse est-elle réaliste pour des données agricoles ?

5.2 Courbe ROC et AUC — Comparaison des trois modèles

Q25. Tracez sur un même graphique les courbes ROC des trois modèles (Arbre de Décision, Forêt Aléatoire, Régression Logistique).

- ↳ Calculez l'AUC (Area Under Curve) pour chaque modèle.
- ↳ Quel modèle a la meilleure AUC ? Cela correspond-il à votre classement par accuracy ?

Q26. Expliquez ce que mesure l'AUC et en quoi elle est plus informative que la simple accuracy.

- ↳ Un modèle avec une accuracy de 75 % peut-il avoir une AUC proche de 0.5 ? Dans quel cas ?
- ↳ Dans notre contexte (prédiction de récoltes), faut-il maximiser l'accuracy ou l'AUC ? Pourquoi ?

EXERCICE 6

Prédiction sur de Nouvelles Données Réelles

15 pts points

Objectif : Utiliser les modèles entraînés pour simuler des prédictions concrètes sur des scenarios agricoles au Burundi et comparer les recommandations des trois modèles.

6.1 Scenarios de prédiction

Vous trouverez ci-dessous **4 scenarios agricoles réels** au Burundi. Pour chaque scenario, utilisez vos trois modèles pour prédire si la récolte sera bonne ou mauvaise, et donnez la probabilité associée.

Province	Culture	Altitude	Pluie (mm)	Temp (°C)	Engrais	Irrigation
Kayanza	Maïs	1 980 m	920	17.8	Oui	Non
Bubanza	Manioc	790 m	550	25.4	Non	Oui
Gitega	Haricot	1 720 m	430	18.2	Non	Non
Cibitoke	Patate douce	810 m	810	24.1	Oui	Oui

Q27. Pour chaque scenario, appliquez les trois modèles et remplissez le tableau suivant.

Scenario	Arbre de Décision	Forêt Aléatoire	Régression Logistique
----------	-------------------	-----------------	-----------------------

Kayanza – Maïs	Bonne/Mauvaise — %	Bonne/Mauvaise — %	Bonne/Mauvaise — %
Bubanza – Manioc	Bonne/Mauvaise — %	Bonne/Mauvaise — %	Bonne/Mauvaise — %
Gitega – Haricot	Bonne/Mauvaise — %	Bonne/Mauvaise — %	Bonne/Mauvaise — %
Cibitoke – Patate douce	Bonne/Mauvaise — %	Bonne/Mauvaise — — %	Bonne/Mauvaise — %

6.2 Interprétation et recommandations

Q28. Les trois modèles sont-ils unanimes pour chaque scénario ? Y a-t-il des désaccords ?

- ↳ Que faire lorsque les modèles ne sont pas d'accord ? Comment décider ?
- ↳ Quel(s) scénario(s) présente(nt) le plus d'incertitude (probabilités proches de 50 %) ?

Q29. Pour le scénario 3 (Gitega – Haricot, pluviométrie très faible de 430 mm), le modèle prédit-il une mauvaise récolte ?

- ↳ Cette prédiction est-elle cohérente avec ce que vous savez de l'agriculture au Burundi ?
- ↳ Quelles actions concrètes un agronome pourrait-il recommander à l'agriculteur de Gitega ?

Q30. Réflexion finale : imaginez que vous êtes conseiller agricole au Ministère de l'Agriculture du Burundi.

- ↳ Lequel des trois modèles recommanderiez-vous de déployer en production ? Pourquoi ?
- ↳ Quelles données supplémentaires permettraient d'améliorer les prédictions ?
- ↳ Quelles limites votre modèle a-t-il ? Peut-on lui faire entièrement confiance ?

EXERCICE 7

Application Web — Déploiement du Modèle

Sur 15 pts points

Objectif : Développer une application web permettant à n'importe quel utilisateur (notamment l'enseignant) de saisir les caractéristiques d'une parcelle agricole et d'obtenir en temps réel une prédiction de récolte.

Important

Réalisez d'abord le pipeline ML complet (exercices 1–6), sauvegardez vos modèles, puis développez l'application web. L'enseignant testera votre application en ligne avec ses propres données agricoles.

7.1 Ce que l'application doit faire

- Afficher un formulaire de saisie avec tous les champs du dataset (province, culture, altitude, pluviométrie, température, superficie, engrais, irrigation)
- Permettre à l'utilisateur de choisir le modèle à utiliser (Arbre de Décision, Forêt Aléatoire, Régression Logistique)
- Afficher la prédiction (Bonne récolte / Mauvaise récolte) avec la probabilité associée
- Afficher les métriques globales du modèle sélectionné (accuracy, F1, AUC)
- (Optionnel) Afficher un graphique d'importance des variables pour la prédiction

7.2 Livrables à remettre

1. Lien GitHub du projet (dépôt public) avec un README expliquant comment lancer l'application
2. URL de l'application déployée et fonctionnelle (accessible par l'enseignant)
3. Capture d'écran de l'interface avec au moins une prédiction effectuée

RÉCAPITULATIF — NOTATION ET LIVRABLES

Ex.	Intitulé	Points	Compétence visée
1	Chargement, Exploration, Qualité des données	20 pts	Analyse exploratoire
2	Prétraitement et préparation	15 pts	Feature engineering
3	Arbre de décision + overfitting	20 pts	Modélisation & interprétation
4	Forêt aléatoire + validation croisée	20 pts	Ensemble learning
5	Régression logistique + courbe ROC	20 pts	Comparaison de modèles
6	Prédiction sur nouveaux scenarios	15 pts	Déploiement & réflexion
7	Application web déployée (BONUS)	15 pts	Ingénierie logicielle

Livrables attendus

4. Un notebook Jupyter (.ipynb) bien structuré et commenté, avec toutes les cellules exécutées
5. Les fichiers modèles sauvegardés (.pkl) pour les 3 algorithmes
6. Un court rapport écrit (1 page max) répondant aux questions de réflexion 29 et 30
7. URL de l'application web déployée + lien GitHub